

Source Depth

이미지별 적응적 깊이 배분을 통한 멀티이미지 환각
완화
27년도 상반기 submission 목표

Multi-Image Hallucination을, 계산을 덜 써서 완화

Depth는 이미지 간 정보가 섞이는 통로.

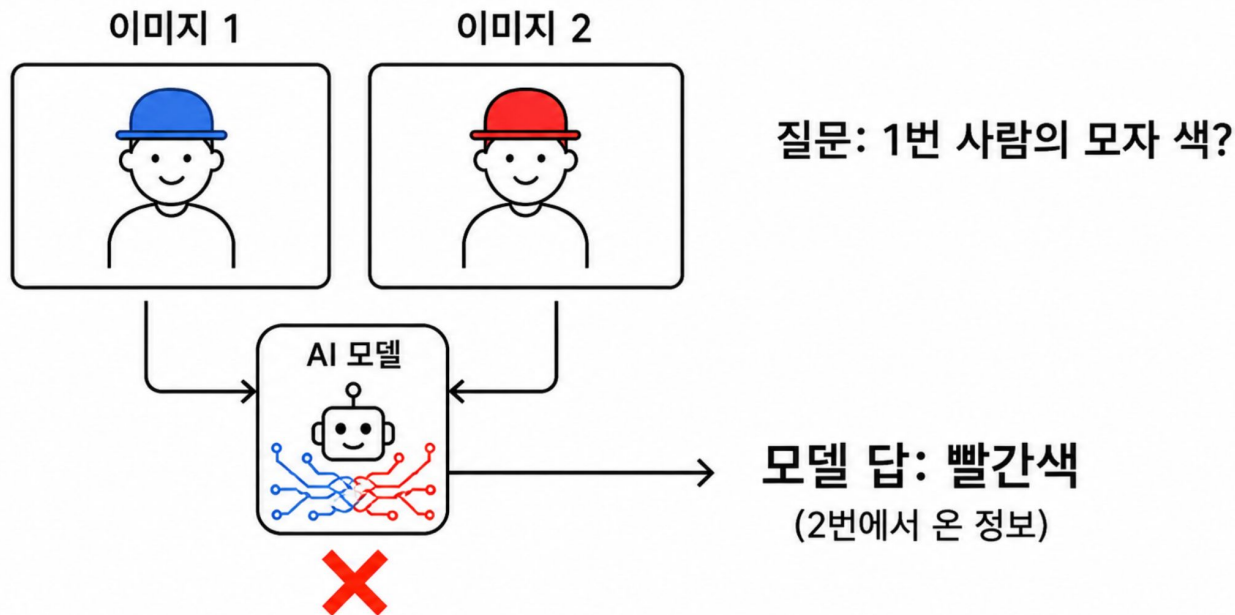
기존 방법들 : 환각을 줄이기 위해 **forward pass**를 N배 사용

Ours : 계산을 줄이면서도 환각이 줄어드는 구간을 **targeting**

핵심 문제 : 여러장의 이미지가 input으로 들어가면, 어느 이미지에서 추출한
정보인지 혼란 발생



현상 : 단일 이미지 대비 멀티 이미지에서 성능이 유의하게 떨어짐

- cross-image information leakage (FOCUS, 2025)
- multi-view hallucination (MVH-Bench, 2026)



서로 다른 이미지 정보가 섞여 잘못 답변

핵심 관찰 : 이미지 간 정보는 **layer**를 지나면서 섞임 = depth가 곧 혼합량



Depth의 양날

: 같은 모델, 같은 depth인데 질문 유형에 따라 depth의 효과가 정반대



필요한 핵심 실험 : 실제로 layer를 더 진행할 수록, target input의 attention이 떨어지는가?

문제 정의

질문 유형에 따라 필요한 깊이가 정반대인데, 현재 모델들은 **depth**가 고정.

질문 유형	필요한 혼합	고정 depth 결과
Unary("1번 자동차 색?")	최소	과잉 혼합 -> source-binding 오류
Relational("어느 쪽이 큰가?")	필수	적정
Distractor 이미지 존재	0	무관 이미지 개입

$$\min \mathbb{E} \left[\sum_i c(d_i) \right] \quad \text{s.t.} \quad P(\text{source-binding error}) \leq \alpha$$

Unary 질문에서는 얇게 계산하는 것이 싸면서 동시에 더 정확할 수 있음

기존 연구 지형 : 기존 연구들은 모두 'full depth' 기준.


연구	개입 지점	비용	depth
FOCUS(2025)	입력 마스킹	N+1 forward	full
Delimiter Token Scaling (ICLR'26)	토큰 hidden state	1 pass	full
RSCD / MVH-Bench (2026)	attention 마스킹	1 pass +	full
Looking Back and Forth (2026)	attention + DPO	학습 필요	full
STEAR (2026, 비디오)	layer-aware evidence 주입	계산 추가	full
AdaSkip/FlexiDepth/Reroute/DARE	depth/토큰 생략	절감	(단일 이미지, 효율 목적)

차별점과 Novelty = 계산을 재배분 / leakage 차단 효과

[3가지 차별점]

1. 관측 : leakage가 어느 depth에서 생기는지 측정한 연구 X (전부 full depth 전제)
2. 메커니즘 : 이미지 I_j 를 layer l에서 생략하면 그 layer에서 아무도 I_j 를 참조할 수 없음
-> KV cache의 구멍이 곧 잘못된 이미지 정보의 leakage 차단
3. 비용 방향 : FOCUS는 N+1 forward pass, Ours는 1 forward pass 미만 목표

후보 Method : Per-image depth



핵심 기여

1. Depth as leakage channel : leakage 발생 depth 구간의 최초 측정 + activation patching 인과 검증
2. Source-attribution risk 신호 : 추가 연산 없이 오류를 예측
3. Per-image adaptive depth : 이미지별 실행 깊이 배분
4. 보증 있는 계산 배분 : 휴리스틱 threshold를 쓰는 기존 skipping과의 구분점
신규 지표 : Source-Binding Error Rate / Relation Preservation / Unsafe Skip Rate / Recovery Rate

데이터셋 / 리소스 / 일정

목적	데이터셋
멀티이미지 종합	MuirBench, MIRB, Mantis-Eval
Source-binding 직접 평가	MVH-Bench
통제 실험	MuirBench 파생 4종 split (순서 / minimal-pair / distractor / relation)
일반 능력 보존	MMBench, MMMU 서브셋

- 모델: Qwen2.5-VL-3B/7B(주) + LLaVA-OneVision-7B(교차 검증). **최소 2개 계열**
- 컴퓨트: **학습 없음**, 총 400–1,000 GPU-hour, 2–4 GPU

Risk / 중단 기준

리스크	완화책
Unary 질문에서 '알수록 정확한 구간' 없음	2개월차 go/no-go. 없으면 "FOCUS와 동일 성능을 1/N 비용으로"라는 시스템 논문으로 pivot
실측 latency가 안 줄어듦	1개월차에 확인. prefill 단계/이미지 단위로만 제한 구현
Baseline 재형 비요	재형 이저의 서바여



Questions

1. 연구과제 관련 프로젝트 함께 수행중에 있음. 승인해주신다면 가을학기까지 쪽이어서 진행하고자 함
2. 가을학기에도 남아있게 된다면 기숙사 이용이 유력한데, 가능하다면 1인실 이용을 희망
3. 자리는 인턴 기간 동안 현 자리 유지인지 / 개인 데스크탑
4. 12월 중순~1월 중순 : 졸업 요건 충족을 위한 과목 수강 필요
5. 1월 중순~2월 첫째주 : 해외 여행 예정